



Πολυτεχνική Σχολή
Τμήμα Μηχανικών Η/Υ & Πληροφορικής

ΕΙΣΑΓΩΓΗ ΣΤΗ ΒΙΟΠΛΗΡΟΦΟΡΙΚΗ

Διερεύνηση Αλγορίθμων και Εργαλείων για την Επεξεργασία και Ανάλυση Βιολογικών Αλληλουχιών

Φίλιππος-Παρασκευάς Ζυγούρης

A.M. 1084660

Πάτρα, 2024

Περιεχόμενα

Ερώτηση 1	4
(i) Διερεύνηση Έτοιμων Εργαλείων.....	4
GBK [GenBank]	4
FRMT [Data Formats].....	5
MEME [New Motif Discovery].....	6
NEED [Pairwise Global Alignment]	6
TFSQ [FASTQ format introduction].....	7
PHRE [Read Quality Distribution]	7
PTRA [Protein Translation].....	8
FILT [Read Filtration by Quality]	8
RVCO [Complementing a Strand of DNA]	9
SUBO [Suboptimal Local Alignment]	9
BPHR [Base Quality Distribution]	9
CLUS [Global Multiple Alignment].....	10
ORFR [Finding Genes with ORFs].....	10
BFIL [Base Filtration by Quality]	10
(ii) Πολλαπλή Στοιχισή.....	11
COBALT	11
MSAViewer	11
Clustal Omega:	12
MUSCLE:.....	12
T-Coffee:	12
MAFFT:.....	13
Σύγκριση Εργαλείων Πολλαπλής Στοιχισής NCBI και EBI	13
Ερώτηση 2	14
i) Στοιχισή Ακολουθιών	14
1. WP_217683847.1	14
2. AAP36762.1	14
3. 6WX6_A	14
ii) Σύγκριση Δομών Πρωτεϊνών	16
6WX6_A_model:	16
AAP36762 1_model:.....	17

WP_217683847 1_model:	18
Ερώτηση 3	19
Ερώτηση 4	23
Ερώτηση 5	26
Ερώτηση 6	29
I. Βέλτιστη Ολική Στοιχίσης.....	29
II. Βέλτιστη Τοπική Στοιχίση	30
Ερώτηση 7	30

Ερώτηση 1

(i) Διερεύνηση Έτοιμων Εργαλείων

Έχω διερευνήσει τη χρήση διαφόρων έτοιμων εργαλείων για την αντιμετώπιση της πληθώρας των διαφορετικών προβλημάτων που εντοπίζονται στον κόσμο της Βιοπληροφορικής. Χρησιμοποίησα έναν συνδυασμό εργαλείων γραμμής εντολών και βιβλιοθηκών με σκοπό να χειριστώ εργασίες που κυμαίνονται από τον χειρισμό της ακολουθίας, έως την αξιολόγηση ποιότητας και την ανακάλυψη μοτίβων. Παρακάτω παρατίθεται μια περίληψη των ευρημάτων μου:

GBK [GenBank]

Το εργαλείο που χρησιμοποιείται είναι: GenBank Database

Η GenBank είναι ένας ανεκτίμητος πόρος, που διατηρείται από το Εθνικό Κέντρο Πληροφοριών Βιοτεχνολογίας (NCBI), καθώς αποτελεί την πιο εκτεταμένη γενετική βάση δεδομένων στον κόσμο, η οποία προσφέρει δεδομένα για την κατανόηση της πολυπλοκότητας των αλληλουχιών του DNA και των πρωτεϊνικών μεταφράσεων τους. Αυτή η ανεκτίμητη πηγή παρέχει σχολιασμένες αλληλουχίες DNA με λεπτομερείς πληροφορίες για τον οργανισμό, ερευνητικά δεδομένα, γονίδια, κώδικες αλληλουχιών, ψευδογονίδια καθώς και άλλα μεταδεδομένα.

Επίσης, είχα πρόσβαση σε ακολουθίες χρησιμοποιώντας την βοήθεια της Biopython, συγκεκριμένα του module Entrez, το οποίο επιτρέπει την πρόσβαση στις βάσεις δεδομένων του NCBI και μέσω μοναδικών αναγνωριστικών, ονομάτων συγγραφέων και συγκεκριμένων λέξεων-κλειδιών απέκτησα αποτελεσματική πρόσβαση σε λεπτομερείς εγγραφές ακολουθίας. Οι προηγμένες δυνατότητες αναζήτησης της GenBank, συμπεριλαμβανομένης της χρήσης Boolean τελεστών, της ακριβούς αντιστοίχισης και της δυνατότητας αναζήτησης σε συγκεκριμένες υποδιαιρέσεις όπως Nucleotide, GSS και EST, μου πρόσφεραν ευελιξία στο να προσαρμόζω τα ερωτήματά μου και να εξετάζω αποτελεσματικά τις γενετικές πληροφορίες για διάφορα είδη. Συνεπώς, οι ερευνητές έχουν την δυνατότητα να ανακτήσουν τις αλληλουχίες των γονιδίων που τους ενδιαφέρουν, όπως το LAMB1, μαζί με τις απαραίτητες πληροφορίες για την κατανόηση των βιολογικών διεργασιών. Αυτό διευκολύνει διάφορες μελέτες, συμπεριλαμβανομένων των συγκρίσεων των αλληλουχιών μεταξύ διαφορετικών οργανισμών ή ειδών. Για μία πιο λεπτομερή ανάλυση, είναι δυνατή η πρόσβαση σε αλληλουχίες της μορφής Fasta, επιτρέποντας στους ερευνητές να εξετάσουν το mRNA και τα εξόνια, γεγονός που βοηθά στην κατανόηση της λειτουργικότητας των γονιδίων και των πιθανών ισομορφών.

FRMT [Data Formats]

Το εργαλείο που χρησιμοποιείται είναι: Διάφορες βιβλιοθήκες και εργαλεία βιοπληροφορικής για την διερεύνηση των μορφών δεδομένων Fasta και GenBank.

Τα βιολογικά δεδομένα είναι διαθέσιμα σε διάφορες μορφές, όπου η κάθε μία από αυτές είναι κατάλληλη για συγκεκριμένους τύπους αναλύσεων. Μερικές από τις πιο κοινές περιλαμβάνουν την GenBank και την μορφή FASTA, που περιέχει δεδομένα ακολουθίας, οι οποίες έχουν σχεδιαστεί με τέτοιο τρόπο ώστε διάφορα εργαλεία βιοπληροφορικής να μπορούν να τις διαβάζουν, να τις κατανοούν και να τις επεξεργάζονται. Αρχικά, η μορφή FASTA είναι μια μέθοδος που βασίζεται σε κείμενο για την αναπαράσταση αλληλουχιών νουκλεοτιδίων ή πρωτεϊνών, όπου η κάθε αλληλουχία ξεκινάει με περιγραφή μίας γραμμής που σημειώνεται με ένα σύμβολο > και ακολουθείται από τα δεδομένα της ακολουθίας, που αναπαρίστανται με κωδικούς ενός γράμματος. Η απλότητα και η ευκολία χειρισμού της την έχουν κάνει μια δημοφιλή επιλογή στην βιοπληροφορική για την αποθήκευση και την ανταλλαγή πληροφοριών αλληλουχίας. Από την άλλη, η μορφή GenBank είναι μια εκτεταμένη και σχολιασμένη βάση δεδομένων ακολουθιών νουκλεοτιδίων, που περιλαμβάνει πλούσιες λεπτομέρειες όπως σχολιασμούς, σχόλια και αναφορές, καθιστώντας την πιο περίπλοκη, αλλά ιδανική για μία ολοκληρωμένη έρευνα. Οι δύο συγκεκριμένες μορφές είναι ζωτικής σημασίας στη βιοπληροφορική, το FASTA για την απλότητα που διαθέτει όταν απαιτούνται μόνο δεδομένα αλληλουχίας και το GenBank για τις εμπειριστατωμένες πληροφορίες που παρέχει για μία ολοκληρωμένη και εις βάθος έρευνα.

Επιπλέον, χρησιμοποιώντας Biopython, εντόπισα αποτελεσματικά τη συντομότερη ακολουθία σε μορφή FASTA για έως και 10 αναγνωριστικά. Με τη συνάρτηση `efetch`, ανέκτησα εγγραφές απλού κειμένου σε μορφή FASTA από τη βάση δεδομένων [Nucleotide] του NCBI και χρησιμοποίησα τη συνάρτηση `parse()` της ενότητας `SeqIO` για να μετατρέψω αυτές τις ακολουθίες σε μια δομημένη λίστα αντικειμένων `SeqRecord`, κατανοώντας καλύτερα τη διαχείριση των δεδομένων ακολουθίας. Αυτές οι διαφορετικές μορφές δεδομένων χρειάζεται να συμμορφώνονται με τις απαιτήσεις της προβλεπόμενης ανάλυσης. Για παράδειγμα, μια ανάλυση Next-Generation Sequencing (NGS) δεν μπορεί να πραγματοποιηθεί σε αρχεία κυττάρων, καθώς αυτά τα αρχεία δεν περιέχουν την απαραίτητη πληροφορία για αυτήν την ανάλυση. Αντίστοιχα, εργαλεία όπως το BLAST, το SwissModel και διάφορα άλλα, απαιτούν την αλληλουχία των δεδομένων σε μορφή FASTA για να λειτουργήσουν σωστά.

MEME [New Motif Discovery]

Το εργαλείο που χρησιμοποιείται είναι: MEME Suite

Με την σουίτα MEME έχω ανακαλύψει κοινά μοτίβα και πρότυπα σε πρωτεϊνικές αλληλουχίες. Εισάγοντας αλληλουχίες σε μορφή FASTA, κατάφερα να ανιχνεύσω κοινά μοτίβα και να αξιολογήσω τη στατιστική τους σημασία, ώστε να βρω ποιο είναι το πιο σημαντικό μοτίβο (καλύτερο βαθμολογικά) που εμφανίζεται σε όλες τις ακολουθίες. Επίσης, η γραφική διεπαφή της σουίτας ήταν καθοριστική για την οπτικοποίηση αυτών των μοτίβων, επιτρέποντας μια διαισθητική κατανόησή τους και της βιολογικής τους σημασίας. Η μορφή FASTA του LAMB1 χρησιμοποιήθηκε για τον εντοπισμό τμημάτων της αλληλουχίας του γονιδίου LAMB1 που παραμένουν σχεδόν αμετάβλητα μεταξύ διαφορετικών ειδών ή μελών της ίδιας οικογένειας γονιδίων μέσω της ανακάλυψης μοτίβων, τα οποία είναι ζωτικής σημασίας για τη φυλογενετική ανάλυση.

NEED [Pairwise Global Alignment]

Το εργαλείο που χρησιμοποιείται είναι: EMBOSS Needle

Η καθολική στοίχιση κατά ζεύγη είναι μια τεχνική που χρησιμοποιείται για την στοίχιση δύο ακολουθιών σε όλο τους το μήκος, για να μεγιστοποιηθούν οι αντιστοιχίσεις και να ελαχιστοποιηθούν τα κενά, προκειμένου να εντοπιστούν ομοιότητες και διαφορές μεταξύ τους. Αυτή η τεχνική είναι απαραίτητη για διάφορες αναλύσεις βιοπληροφορικής, συμπεριλαμβανομένων των εξελικτικών μελετών και της ανάλυσης αλληλουχίας, καθώς αποκαλύπτει ομοιότητες μεταξύ ειδών και διαφορές λειτουργικής διαφοροποίησης. Χρησιμοποιώντας το εργαλείο EMBOSS Needle, πραγματοποίησα στοίχιση κατά ζεύγη συμβολοσειρών DNA και RNA, που παρέχονται σε μορφή FASTA, λαμβάνοντας αποτελέσματα με βαθμολογίες που υποδεικνύουν ομοιότητα αλληλουχίας με βάση συγκεκριμένους κανόνες βαθμολόγησης, όπως ο πίνακας αποτελεσμάτων DNAfull, ο οποίος λαμβάνει υπόψη τις αντιστοιχίσεις, τις αναντιστοιχίες, συμπεριλαμβανομένων των διφορούμενων νουκλεοτιδίων και εφαρμογή ειδικών κυρώσεων για διάφορα ανοίγματα και επεκτάσεις κενού. Τα κενά τα έλαβα υπόψιν βάζοντας ειδικές εντολές ως ορίσματα στη γραμμή εντολών του εργαλείου. Η έξοδος, σε μορφή ζεύγους, δείχνει την τελική στοίχιση των δύο ακολουθιών και τη μέγιστη συνολική βαθμολογία στοίχισής τους, η οποία ποσοτικοποιεί το επίπεδο ομοιότητας μεταξύ των ακολουθιών. Τα αποτελέσματα BLAST για το LAMB1 παρείχαν παρόμοιες αλληλουχίες, συμπεριλαμβανομένων λεπτομερών στοίχισεων ανά ζεύγη που εμφανίζουν κενά, ταιριασμένες και αταίριαστες περιοχές, βοηθώντας έτσι στην επιλογή παρόμοιων αλληλουχιών για περαιτέρω ανάλυση.

TFSQ [FASTQ format introduction]

Το εργαλείο που χρησιμοποιείται είναι: Biopython.

Η μορφή FASTQ, η οποία αποτελεί μία τροποποίηση του FASTA, περιλαμβάνει πρόσθετες πληροφορίες ποιότητας για κάθε βάση, που αντιπροσωπεύονται από ειδικούς χαρακτήρες. Αυτά τα δεδομένα ποιότητας είναι ζωτικής σημασίας για την ανάλυση ποιοτικού ελέγχου στις τεχνολογίες NGS, καθοδηγώντας την περαιτέρω ανάλυση. Με βάση την αναφορά ποιότητας, οι ακολουθίες μπορούν να περικοπούν για να βελτιωθεί η ποιότητά τους εάν είναι απαραίτητο. Με την βοήθεια της Biopython κατανόησα πιο αποτελεσματικά τη μορφή FASTQ που χρησιμοποιείται για να αποθηκεύσει τόσο την ακολουθία DNA, όσο και την ποιότητα της ανάγνωσης για κάθε βάση. Επίσης, ανέλυσα τα αρχεία FASTQ για να εξάγω αναγνώσεις ακολουθίας και βαθμολογίες ποιότητας, αποκτώντας πληροφορίες για την ποιότητα της ακολουθίας και την ακεραιότητα των δεδομένων. Έπειτα μετέτρεψα από τη μορφή FASTQ σε FASTA, κρατώντας μόνο την ακολουθία του DNA και αφαιρώντας τις πληροφορίες ποιότητας.

PHRE [Read Quality Distribution]

Το εργαλείο που χρησιμοποιείται είναι: FastQC (Galaxy Server)

Αυτή η μορφή αφορά την κατανομή της ποιότητας ανάγνωσης κάθε βάσης, που παρέχεται στα αρχεία FASTQ που αναφέρονται στην ποιότητα αλληλουχίας της κάθε βάσης που υπάρχει στην αλληλουχία. Αυτή η βαθμολογία ποιότητας παρέχει πληροφορίες για τη συνολική ποιότητα της αλληλουχίας. Η ανάλυση της κατανομής ποιότητας ανάγνωσης είναι κρίσιμη για την αξιολόγηση της αξιοπιστίας των δεδομένων αλληλουχίας. Με βάση την αξιολόγηση της ποιότητας, πραγματοποιείται κόψιμο και φιλτράρισμα, βοηθώντας στην διασφάλιση της ακρίβειας των επόμενων αναλύσεων. Οι βαθμολογίες ποιότητας στα αρχεία FASTQ που ελήφθησαν στο προηγούμενο βήμα είναι στην πραγματικότητα βαθμολογίες ποιότητας phred, αντιπροσωπεύονται από ειδικούς χαρακτήρες και είναι ζωτικής σημασίας για την αξιολόγηση της αξιοπιστίας των δεδομένων αλληλουχίας. Χρησιμοποιώντας το FastQC μέσω του Galaxy "Andromeda", αξιολόγησα τις αναγνώσεις της αλληλουχίας DNA, υπολογίζοντας τη μέση βαθμολογία ποιότητας για κάθε ακολουθία. Έπειτα, ανέλυσα τα αρχεία FASTQ, εξήγα κρίσιμες μετρήσεις, συμπεριλαμβανομένων των βαθμολογιών ποιότητας ανά βάση, που υποδεικνύουν πόσο αξιόπιστη είναι κάθε βάση DNA και της κατανομής μήκους της ακολουθίας και επέβαλα ένα αυστηρό κατώφλι ελέγχου ποιότητας δεδομένων, ώστε να

διασφαλίσω την ακεραιότητα των δεδομένων αλληλουχίας και να μετρήσω πόσες ακολουθίες έχουν μέση βαθμολογία κάτω από το δεδομένο αυτό κατώφλι.

PTRA [Protein Translation]

Το εργαλείο που χρησιμοποιείται είναι: Translate tool from the SMS 2 package

Η μετάφραση πρωτεΐνης είναι η διαδικασία μετατροπής μιας αλληλουχίας DNA στην αντίστοιχη αλληλουχία αμινοξέων σε μια πρωτεΐνη. Αυτό αποτελεί ένα θεμελιώδες βήμα στη γονιδιωματική, την πρωτεϊνική και τη μοριακή βιολογία, το οποίο επιτρέπει την ακριβή πρόβλεψη των πρωτεϊνικών αλληλουχιών που κωδικοποιούνται από το DNA. Βοηθά στην πρόβλεψη της γονιδιακής λειτουργίας, στην ανάλυση της πρωτεϊνικής δομής και στην κατανόηση των επιπτώσεων των γενετικών παραλλαγών. Η GenBank παρέχει μεταφρασμένες πρωτεϊνικές αλληλουχίες για γονίδια, συμπεριλαμβανομένου του LAMB1. Χρησιμοποιώντας το εργαλείο μετάφρασης του πακέτου SMS 2, μετέφρασα αλληλουχίες νουκλεοτιδίων σε πρωτεϊνικές αλληλουχίες εισάγοντας την αλληλουχία DNA σε μορφή FASTA στο παράθυρο κειμένου και το εργαλείο παρείχε την αλυσίδα αμινοξέων, που αντιπροσωπεύει τα δομικά στοιχεία των πρωτεϊνών. Παρατήρησα ότι η διαδικασία μετάφρασης δεν ξεκινά πάντα με το πρώτο νουκλεοτίδιο, αλλά σε συγκεκριμένες θέσεις με βάση το πλαίσιο ανάγνωσης, καθώς το DNA διαβάζεται σε ομάδες των τριών γραμμάτων για να σχηματιστούν κωδικόνια. Εστιάζοντας στον άμεσο κλώνο του DNA, το οποίο χρησιμοποιείται για την παραγωγή της πρωτεΐνης εφάρμοσα τον τυπικό γενετικό κώδικα για να αποκρυπτογραφήσω / μεταφράσω τις τριπλέτες των νουκλεοτιδίων σε αμινοξέα.

FILT [Read Filtration by Quality]

Το εργαλείο που χρησιμοποιείται είναι: Το φίλτρο ποιότητας FASTQ της διαδικτυακής πλατφόρμας Galaxy.

Αυτή η διαδικασία περιλαμβάνει ποιοτικό φιλτράρισμα των αναγνώσεων ακολουθίας με βάση τις βαθμολογίες ποιότητας. Οι αναγνώσεις χαμηλής ποιότητας αφαιρούνται για να αποφευχθούν ψευδείς προβλέψεις και παρερμηνείες σε επόμενες αναλύσεις. Τα τυπικά βήματα προεπεξεργασίας στην ανάλυση δεδομένων NGS διασφαλίζουν την βελτίωση των σφαλμάτων αλληλουχίας και της ακρίβειας των δεδομένων. Χρησιμοποίησα το φίλτρο ποιότητας FASTQ της πλατφόρμας Galaxy για τον ποιοτικό έλεγχο της αλληλουχίας DNA. Πρώτα, εισήγαγα το αρχείο FASTQ, για την αποθήκευση των αλληλουχιών DNA μαζί με τους βαθμούς ποιότητάς τους. Έπειτα, καθόρισα την βαθμολογία αποκοπής ποιότητας και καθόρισα το ποσοστό των βάσεων που πρέπει να πληρούν ή να υπερβαίνουν αυτό το όριο. Το φίλτρο απορρίπτει αλληλουχίες που δεν πληρούν τα κριτήρια ποιότητας, με αποτέλεσμα καλύτερα, ταχύτερα αποτελέσματα με ελάχιστη χρήση

μνήμης, διατηρώντας μόνο αλληλουχίες DNA υψηλής ποιότητας.

RVCO [Complementing a Strand of DNA]

Το εργαλείο που χρησιμοποιείται είναι: Το Sequence Manipulation Suite του προγράμματος Reverse Complement από το πακέτο SMS 2.

Για να αντιστρέψω την αλληλουχία, παίρνω τη δεδομένη αλληλουχία DNA και αντιστρέφω τη σειρά των νουκλεοτιδίων της. Για την συμπλήρωση, αντικαθιστώ κάθε νουκλεοτίδιο με το συμπλήρωμά του. Στη συνέχεια, κάνω επικόλληση των αλληλουχιών DNA στην παρεχόμενη περιοχή κειμένου, διασφαλίζοντας ότι η κάθε ακολουθία βρίσκεται μετά από την καθορισμένη ετικέτα. Επιλέγω την αντίστροφη συμπλήρωση και, στη συνέχεια το υποβάλω, για να γίνει η επεξεργασία. Τελικά, το εργαλείο εξάγει το αντίστροφο συμπλήρωμα κάθε παρεχόμενης αλληλουχίας DNA. Αυτή η μέθοδος επιτρέπει στους ερευνητές να χειριστούν εύκολα τις αλληλουχίες DNA για να μελετήσουν τη συμμετρία της αλληλουχίας και τη σύζευξη των βάσεων.

SUBO [Suboptimal Local Alignment]

Το εργαλείο που χρησιμοποιείται είναι: Πρόγραμμα Lalign

Αυτός ο τύπος στοίχισης πραγματοποιείται μεταξύ δύο αλληλουχιών με σκοπό να μεγιστοποιήσει τις τοπικές ομοιότητες οποιασδήποτε περιοχής ενδιαφέροντος, καθώς δεν παράγει την καλύτερη συνολική στοίχιση. Αυτή η διαδικασία είναι χρήσιμη για τον εντοπισμό συντηρημένων περιοχών ή δομών εντός των αλληλουχιών. Τα αποτελέσματα της στοίχισης βοηθούν στην ανίχνευση ασθενών ομοιοτήτων αλληλουχιών που μπορεί να έχουν αγνοηθεί από τις παραδοσιακές μεθόδους στοίχισης.

BPHR [Base Quality Distribution]

Το εργαλείο που χρησιμοποιείται είναι: Per Base Sequence Quality του προγράμματος FastQC.

Το συγκεκριμένο εργαλείο περιγράφει την ποιότητα της κάθε βάσης στις αναγνώσεις της αλληλουχίας. Η αξιοπιστία των κλήσεων βάσεων στην αλληλουχία εξασφαλίζεται από την κατανομή της ποιότητας της βάσης. Περιοχές με δεδομένα χαμηλής ποιότητας μπορούν να εντοπιστούν από την κατανομή της ποιότητας της βάσης και να υποστούν επεξεργασία για φιλτράρισμα και κόψιμο εάν είναι

απαραίτητο, γεγονός που αποτελεί ένα αναγκαίο βήμα για την επίτευξη μίας καλής ποιότητας και πιο ακριβών επόμενων αναλύσεων.

CLUS [Global Multiple Alignment]

Το εργαλείο που χρησιμοποιείται είναι: ClustalW2

Η στοίχιση πολλών αλληλουχιών ταυτόχρονα με πλήρη κάλυψη της αλληλουχίας είναι γνωστή ως παγκόσμια πολλαπλή στοίχιση. Μπορεί να πραγματοποιηθεί χρησιμοποιώντας διάφορα εργαλεία όπως το Clustal Omega, το Mega, κ.λπ. Αυτό μπορεί να πραγματοποιηθεί για τον εντοπισμό εξελικτικών σχέσεων και συντηρημένων περιοχών. Η ομολογία αλληλουχίας μπορεί να εντοπιστεί μεταξύ διαφορετικών ειδών.

ORFR [Finding Genes with ORFs]

Το εργαλείο που χρησιμοποιείται είναι: Ο ανιχνευτής ORF από το πακέτο SMS 2.

Η εύρεση γονιδίων με ORFs περιλαμβάνει τον εντοπισμό περιοχών στις αλληλουχίες DNA που μπορούν να κωδικοποιηθούν σε πρωτεΐνες. Αυτές οι περιοχές μπορούν να μεταγραφούν και να μεταφραστούν σε πρωτεΐνες. Οι αναλύσεις του γονιδιώματος απαιτούν κριτικά τις πληροφορίες των ORFs. Οι ερευνητές μπορούν να χρησιμοποιήσουν αυτές τις πληροφορίες για να εντοπίσουν κωδικοποιημένες αλληλουχίες και να σχολιάσουν τα γονιδιώματα για περαιτέρω ανάλυση.

BFIL [Base Filtration by Quality]

Το εργαλείο που χρησιμοποιείται είναι: Εργαλείο περικοπής ποιότητας FASTQ στο Galaxy.

Αυτή η διαδικασία φιλτράρει τις βάσεις εντός των αναγνώσεων της αλληλουχίας με βάση την κατανομή της ποιότητας της βάσης. Αναγνώσεις χαμηλής ποιότητας μπορούν να αφαιρεθούν για να βελτιωθεί η ποιότητα της συνολικής αλληλουχίας και η ακρίβεια των επόμενων αναλύσεων. Αποτελεί ένα από τα κρίσιμα βήματα στην προεπεξεργασία της ανάλυσης δεδομένων NGS.

(ii) Πολλαπλή Στοιχίση

Οι δύο μεγαλύτερες βάσεις δεδομένων νουκλεοτιδικών αλληλουχιών, GENBANK του NCBI και EMBL του EBI, έχουν ορισμένες διαφορές όσον αφορά τη δομή, τις δυνατότητες και τις υπηρεσίες που προσφέρουν. Η GENBANK είναι μια βάση δεδομένων υπό την αιγίδα του Εθνικού Ινστιτούτου Υγείας των Η.Π.Α., που περιέχει δεδομένα από ερευνητικές ομάδες και επεξεργάζεται υποβολές μέσω διαδικτύου. Οι εγγραφές στη GENBANK σχολιάζονται και δημοσιοποιούνται, με τα δεδομένα να αναθεωρούνται συχνά για ακρίβεια και ενημέρωση. Η βάση δεδομένων υποστηρίζει μεγάλο όγκο δεδομένων, με πάνω από 181 εκατομμύρια ακολουθίες και πάνω από 188 δισεκατομμύρια νουκλεοτιδικές βάσεις.

Από την άλλη πλευρά, η EMBL Nucleotide Sequence Database, υπό την αιγίδα του Ευρωπαϊκού Εργαστηρίου Μοριακής Βιολογίας (EMBL) και του Ευρωπαϊκού Ινστιτούτου Βιοπληροφορικής (EBI), είναι η μεγαλύτερη βάση δεδομένων στην Ευρώπη. Οι ακολουθίες κατατίθενται από ερευνητικά εργαστήρια μέσω διαδικτύου και επεξεργάζονται πριν δημοσιοποιηθούν. Η EMBL-Bank προσφέρει διάφορα εργαλεία ανάλυσης όπως το Fasta και το BLAST και περιέχει πάνω από 510 εκατομμύρια εγγραφές με συνολικά πάνω από 1 τρισεκατομμύριο νουκλεοτίδια.

Παρά τις ομοιότητες στη συνεργασία και την ανταλλαγή δεδομένων, το NCBI και το EBI διατηρούν τις δικές τους μοναδικές διαδικασίες και εργαλεία για την πολλαπλή στοιχίση αλληλουχιών πρωτεϊνών από μια υπεροικογένεια που διαφέρουν μεταξύ τους. Αυτή η διαδικασία είναι εξαιρετικά δύσκολη εξαιτίας την μικρής ομοιότητας των αλληλουχιών, παρόλο που μπορεί να υπάρχουν παρά τις σαφείς εξελικτικές σχέσεις και τις λειτουργικές και δομικές ομοιότητες.

Εργαλεία Πολλαπλής Στοιχίσης NCBI:

COBALT

Το COBALT είναι ένα προηγμένο εργαλείο πολλαπλής στοιχίσης αλληλουχιών που αξιοποιεί βάσεις δεδομένων συντηρημένων περιοχών και μοτίβων πρωτεϊνών για την παραγωγή. Ενσωματώνει περιορισμούς από RPS-BLAST, BLASTP και PHI-BLAST, επιτρέποντας λεπτομερή ανάλυση πρωτεϊνικών αλληλουχιών. Επιπλέον, υποστηρίζει μεγάλα σύνολα δεδομένων και προσφέρει ευελιξία με επιλογές για ποινές κενών και για ομαδοποίηση ερωτημάτων. Η σύνδεσή του με άλλα εργαλεία του NCBI διευκολύνει την πρόσβαση σε συμπληρωματικές πληροφορίες και ανάλυση, καθιστώντας το ένα ισχυρό εργαλείο για μελέτες βιοπληροφορικής υψηλής ακρίβειας.

MSAViewer

Το MSAViewer είναι ένα εξελιγμένο εργαλείο το οποίο επιτρέπει την διαδραστική οπτικοποίηση πολλαπλών στοιχειών νουκλεοτιδικών και πρωτεϊνικών αλληλουχιών.

Παρέχει τη δυνατότητα προσαρμογής των ρυθμίσεων εμφάνισης και των χρωματικών σχημάτων, διευκολύνοντας περισσότερο την ανάλυση. Επιπλέον, το MSASViewer υποστηρίζει την εμφάνιση σχολίων για συντηρημένες και λειτουργικές περιοχές, προσφέροντας έτσι πολύτιμες πληροφορίες για την βιολογική σημασία των αλληλουχιών. Περιλαμβάνει εργαλεία για μεγέθυνση, πανόραμα και αναζήτηση συγκεκριμένων αλληλουχιών, επιτρέποντας με αυτό τον τρόπο την εστίαση σε περιοχές ενδιαφέροντος. Επιπλέον, δίνει τη δυνατότητα εξαγωγής των δεδομένων σε διάφορες μορφές, διευκολύνοντας τη διαχείριση και την περαιτέρω ανάλυση των αποτελεσμάτων.

EBI Εργαλεία Πολλαπλής Στοιχίσης

Το EBI Sequence Manipulation Suite προσφέρει πρόσβαση σε διάφορα εργαλεία για πολλαπλή στοιχίση, ορισμένα από τα πιο κρίσιμα είναι:

Clustal Omega:

Το EBI προσφέρει το Clustal Omega για την πολλαπλή στοιχίση αλληλουχιών αμινοξέων ή νουκλεοτιδίων. Το Clustal Omega έχει σχεδιαστεί για να παρέχει μία στοιχίση υψηλής ακρίβειας, καθιστώντας το μια αξιόπιστη επιλογή για πιο ακριβείς αναλύσεις. Είναι πολύ σημαντικό το ότι μπορεί να διαχειριστεί μεγάλα σύνολα δεδομένων αποτελεσματικά, διασφαλίζοντας την κλιμάκωση πιο σύνθετων εργασιών. Το Clustal Omega ενσωματώνεται άψογα με άλλα εργαλεία βιοπληροφορικής και βάσεις δεδομένων, προσφέροντας μεγαλύτερη ευελιξία στη χρήση. Οι χρήστες έχουν πρόσβαση τόσο σε διαδικτυακές όσο και σε γραμμικές διεπαφές, καλύπτοντας ένα σύνολο από διαφορετικές προτιμήσεις και ανάγκες.

MUSCLE:

Το Muscle είναι ένα άλλο εργαλείο του EBI, το οποίο σημαίνει "multiple sequence comparison by log-expectation", και επικεντρώνεται στην ακρίβεια και την απόδοση στην πολλαπλή στοιχίση μεταξύ των αλληλουχιών. Είναι ιδιαίτερα γνωστό για τη δυνατότητά του να διαχειρίζεται αποτελεσματικά μεγάλα σύνολα δεδομένων και για την αξιοπιστία του στην παραγωγή πιο ακριβών στοιχίσεων.

T-Coffee:

Το T-Coffee (Tree-based Consistency Objective Function for Alignment Evaluation) λειτουργεί ως εργαλείο για την πολλαπλή στοιχίση αλληλουχιών με εξειδίκευση στη βιοπληροφορική και χρησιμοποιεί πληροφορίες ομοιότητας αλληλουχιών και δομικών δεδομένων για βελτιωμένη ακρίβεια. Ο χρήστης ξεκινάει καταβάλλοντας αλληλουχίες από το NCBI και εισάγοντας τις στο T-Coffee. Είναι σημαντικό να καθοριστεί εάν οι αλληλουχίες είναι πρωτεΐνες ή νουκλεοτίδια. Το εργαλείο επιλέγει την κατάλληλη μέθοδο στοιχίσης και παρέχει επιλογές εξόδου, όπως HTML, Cluster

W ή Fasta. Οι χρήστες μπορούν να υποβάλλουν την εργασία τους και να λαμβάνουν αποτελέσματα μέσω email. Το T-Coffee παρέχει στη συνέχεια στοίχιση αλληλουχιών με χρωματική κωδικοποίηση για να ερμηνεύσουν την ποιότητα της στοίχισης και δημιουργεί φυλογενετικά δέντρα για την εξέλιξη των σχέσεων.

MAFFT:

Το MAFFT είναι ένα εργαλείο πολλαπλής στοίχισης αλληλουχιών που ξεχωρίζει για την ευελιξία και την απόδοσή του. Προσφέρει μια ποικιλία αλγορίθμων στοίχισης, οι οποίοι επιτρέπουν στους χρήστες να επιλέξουν την καταλληλότερη μέθοδο ανάλογα με τις συγκεκριμένες ανάγκες της ανάλυσής τους. Ένα από τα κύρια πλεονεκτήματα του MAFFT είναι η ικανότητά του να υποστηρίζει και να επεξεργάζεται μεγάλα σύνολα δεδομένων, καθιστώντας το ιδανικό για αναλύσεις που απαιτούν την στοίχιση πολλαπλών αλληλουχιών από μεγάλες βάσεις δεδομένων. Επιπλέον, διαχειρίζεται αποδοτικά αποκλίνουσες αλληλουχίες, παρέχοντας ακριβή και αξιόπιστα αποτελέσματα ακόμα και σε περιπτώσεις όπου οι αλληλουχίες παρουσιάζουν σημαντικές διαφοροποιήσεις. Αυτά τα χαρακτηριστικά καθιστούν το MAFFT ένα εξαιρετικά χρήσιμο εργαλείο για εφαρμογές βιοπληροφορικής που απαιτούν την ευθυγράμμιση σύνθετων και μεγάλων συνόλων αλληλουχιών.

Σύγκριση Εργαλείων Πολλαπλής Στοίχισης NCBI και EBI:

Συνολικά, τα εργαλεία του NCBI χαρακτηρίζονται από την ταχύτητα, την ακρίβεια, την ευελιξία και την ικανότητά τους να ενσωματώνονται άψογα με άλλες βάσεις δεδομένων, γεγονός που τα καθιστά ιδανικά για ολοκληρωμένες αναλύσεις βιοπληροφορικής. Από την άλλη, τα εργαλεία του EBI είναι σχεδιασμένα για υψηλή ακρίβεια, ευελιξία και διαλειτουργικότητα, και είναι ιδιαίτερα χρήσιμα για εφαρμογές που απαιτούν ακριβείς και αξιόπιστες στοιχίσεις αλληλουχιών.

Ερώτηση 2

i) Στοίχιση Ακολουθιών

Μετά την εκτέλεση BLASTP στο NP_000137, οι τρεις πρωτεΐνες που επιλέχθηκαν είναι οι εξής:

1. WP_217683847.1

α. Οργανισμός: *Pseudomonas aeruginosa*, ένα κοινό βακτήριο γνωστό για το ρόλο του σε διάφορες λοιμώξεις.

β. Ορισμός: Η ίδια η πρωτεΐνη περιέχει μια περιοχή παρόμοια με τη φερριτίνη, η οποία είναι ένα σύμπλεγμα πρωτεϊνών που αποθηκεύει και απελευθερώνει σίδηρο στα κύτταρα. Ωστόσο, η αλληλουχία που παρέχεται είναι μερική, που σημαίνει ότι δεν αντιπροσωπεύει την πρωτεΐνη πλήρους μήκους, αλλά μόνο ένα μέρος της.

2. AAP36762.1

α. Οργανισμός: *Homo sapiens* ή ο άνθρωπος.

β. Ορισμός: Η πρωτεΐνη είναι μια μερική αλληλουχία φερριτίνης, συγκεκριμένα το ελαφρύ πολυπεπτίδιο, η αλληλουχία δεν είναι το πλήρες πολυπεπτίδιο αλλά μόνο ένα μέρος του. Αποτελεί συνθετικό κατασκευάσμα, που σημαίνει ότι η αλληλουχία δημιουργήθηκε ή τροποποιήθηκε τεχνητά για ερευνητικούς ή πειραματικούς σκοπούς.

3. 6WX6_A

α. Οργανισμός: *Homo sapiens*,

β. Ορισμός: Αλυσίδα A, η οποία αντιστοιχεί στην ελαφριά αλυσίδα της φερριτίνης.

Η μορφή FASTA αυτών των ακολουθιών αποθηκεύτηκε σε ένα μόνο αρχείο και πραγματοποιήθηκε μια στοίχιση πολλαπλών ακολουθιών χρησιμοποιώντας T-COFFEE. Παρατηρήθηκε βαθμολογία 998, υποδεικνύοντας ότι οι περισσότερες αλληλουχίες στοχίστηκαν με καλή βαθμολογία ποιότητας, όπως φαίνεται στην παρακάτω στοίχιση:

T-COFFEE, Version_11.00 (Version_11.00)

Cedric Notredame

SCORE=998

*


BAD AVG GOOD

* : 99
pdb|6WX6|A : 99
AAP36762.1 : 100
WP_217683847.1 : 99
Cons : 99

pdb|6WX6|A TGWSHPQFEKLKGGSSRGGGGGSGGS
GGS
AAP36762.1 WP_217683847.1 P
AGLSLASTVFGRNRSGDSLPAASDRPPISSPLATSGTIFSAISCF
WDLPAFLWLAPSC

cons 

pdb|6WX6|A
GGSMSSQIRQNYSTDVEAAVNSLVNLYLQASYTYLSLGFYFDRDDVALEGVSHF
FRELAEEKREGY AAP36762.1 ---
MSSQIRQNYSTDVEAAVNSLVNLYLQASYTYLSLGFYFDRDDVALEGVSHFFREL
AEEKREGY WP_217683847.1
QPTMSSQIRQNYSTDVEAAVNSLVNLYLQASYTYLSLGFYFDRDDVALEGVSHF
FRELAEEKREGY

cons

pdb|6WX6|A
AAP36762.1
WP_217683847.1
ERLLKMQNQRGGRALFQDIKKPAEDEWGKTPDAMKAAMAL
EKKLNQALLDLHALGSARTDPHLCDF
ERLLKMQNQRGGRALFQDIKKPAEDEWGKTPDAMKAAMAL
EKKLNQALLDLHALGSARTDPHLCDF
ERLLKMQNQRGGRALFQDIKKPAEDEWGKTPDAMKAAMAL
EKKLNQALLDLHALGSARTDPHLCDF

cons

```

*****
*****

pdb| 6WX6|A      LETHFLDEEVKLIKMGDHLTNLHRLGGPEAGLGEYLFERLT
AAP36762.1      LRHDGGSGGSGGSGGSGGGASGGS
                  LETHFLDEEVKLIKMGDHLTNLHRLGGPEAGLGEYLFERLT
                  LKHDL-----
WP_217683847.1  LETHFLDEEVKLIKMGDHLTNLHRLGGPEAGLGEYLFERLT LKHD-
                  -----

cons            *****:

```

ii) Σύγκριση Δομών Πρωτεϊνών

6WX6_A_model:

Οι μοντελοποιημένες δομές του 6WX6 συγκρίθηκαν χρησιμοποιώντας εργαλεία Dali και εντοπίστηκαν οι δέκα κορυφαίες αντιστοιχίσεις με τη δομή της πρωτεΐνης του προηγούμενου ερωτήματος. Οι περισσότερες από αυτές τις δομές έδειξαν 55-56% ταυτότητα. Δεδομένου ότι η δομή ήταν η αλυσίδα A του 6WX6, πολλές από τις παρατηρούμενες δομές είναι επίσης αλυσίδες που αποτελούν μέρος σύνθετων πρωτεϊνικών δομών. Το RMSD=0,2 υποδεικνύει ότι το 20% των αμινοξέων διέφερε ή παρέκκλινε από τη δομή της πρωτεΐνης. Επιπλέον, η βαθμολογία Z=30,2 υποδηλώνει σημαντική αλλαγή και απόκλιση μεταξύ της ενδιαφερόμενης πρωτεΐνης και των άλλων δομών.

Sr.#	Chain	Z	Rmsd	Lali	nres	%id	Description
1	6ftv-A	30.2	0.2	173	173	56	MOLECULE: FERRITIN HEAVY CHAIN;
2	7ck8-L	30.2	0.2	173	173	55	MOLECULE: FERRITIN HEAVY CHAIN;
3	3ajo-A	30.2	0.2	172	172	56	MOLECULE: FERRITIN HEAVY CHAIN;
4	5n27-A	30.2	0.2	173	174	56	MOLECULE: FERRITIN HEAVY CHAIN;
5	3ajp-A	30.2	0.2	172	172	56	MOLECULE: FERRITIN HEAVY CHAIN;

6	7pf1-N	30.2	0.2	173	174	56	FERRITIN CHAIN, TERMINALLY PROCESSED;	HEAVY N-
7	7pf1-L	30.2	0.2	173	174	56	FERRITIN CHAIN, TERMINALLY PROCESSED;	HEAVY N-
8	7pf1-O	30.2	0.2	173	174	56	FERRITIN CHAIN, TERMINALLY PROCESSED;	HEAVY N-
9	4y08-A	30.2	0.2	172	172	56	MOLECULE: FERRITIN HEAVY CHAIN;	
10	7ck8-I	30.2	0.2	172	172	56	MOLECULE: FERRITIN HEAVY CHAIN;	

AAP36762 1_model:

Οι μοντελοποιημένες δομές του AAP36762.1 συγκρίθηκαν επίσης με τη χρήση εργαλείων Dali και ακολουθούν οι δέκα κορυφαίες αντιστοιχίσεις που βρέθηκαν με τη δομή της πρωτεΐνης του προηγούμενου ερωτήματος. Οι περισσότερες από αυτές τις δομές εμφανίζουν 83-88% ομοιότητα. Το RMSD είναι 0,2, που υποδεικνύει ότι το 20 των αμινοξέων διαφέρει ή αποκλίνει από τη δομή της ενδιαφερόμενης πρωτεΐνης. Η βαθμολογία Z=29,4 υποδηλώνει σημαντική αλλαγή και απόκλιση μεταξύ της ενδιαφερόμενης πρωτεΐνης και των άλλων δομών. Επιπλέον, μπορεί να παρατηρηθεί ότι οι περισσότερες από τις ταιριασμένες δομές παρουσιάζουν ομοιότητα με τις αλυσίδες A τους.

Sr.#	Chain	Z	rmsd	Lali	nres	%id	Description
1	1lb3-A	29.4	0.2	166	166	83	MOLECULE: FERRITIN LIGHT CHAIN 1;
2	1h96-A	29.3	0.2	166	166	83	MOLECULE: FERRITIN LIGHT CHAIN 1;
3	6z3d-A	29.0	0.2	166	169	83	MOLECULE: FERRITIN;
4	3rd0-A	28.9	0.2	168	168	88	MOLECULE: FERRITIN LIGHT CHAIN;
5	3f32-A	28.9	0.2	168	168	88	MOLECULE: FERRITIN LIGHT CHAIN;
6	6z3d-E	28.9	0.2	166	170	83	MOLECULE: FERRITIN;

7	1xz1-A	28.9	0.2	168	168	88	MOLECULE: FERRITIN LIGHT CHAIN;
8	3f39-A	28.9	0.2	168	168	88	MOLECULE: FERRITIN LIGHT CHAIN;
9	3f34-A	28.9	0.2	168	168	88	MOLECULE: FERRITIN LIGHT CHAIN;
10	3f38-A	28.9	0.2	168	168	88	MOLECULE: FERRITIN LIGHT CHAIN;

WP_217683847 1_model:

Οι μοντελοποιημένες δομές του WP_217683847.1 συγκρίθηκαν επίσης χρησιμοποιώντας εργαλεία Dali και οι δέκα κορυφαίες αντιστοιχίσεις με τη πρωτεϊνική δομή του προηγούμενου ερωτήματος παρατίθενται παρακάτω. Οι περισσότερες από αυτές τις δομές δείχνουν 99% ταυτότητα. Ωστόσο, το RMSD=0,3 υποδεικνύει ότι το 30% των αμινοξέων διαφέρει ή αποκλίνει από τη δομή της πρωτεΐνης του προηγούμενου ερωτήματος. Η βαθμολογία Z=26,3 υποδηλώνει σημαντική αλλαγή και απόκλιση μεταξύ της ενδιαφερόμενης πρωτεϊνικής δομής και των άλλων δομών. Επιπλέον, μπορεί να παρατηρηθεί ότι οι περισσότερες από τις ταιριασμένες δομές είναι διαφορετικές αλυσίδες 6WX6.

Sr.#	Chain	Z	rmsd	lali	nres	%id	Description
1	6wx6-I	26.3	0.3	172	172	99	MOLECULE: FERRITIN LIGHT CHAIN;
2	6wx6-B	26.3	0.3	172	172	99	MOLECULE: FERRITIN LIGHT CHAIN;
3	6wx6-R	26.3	0.3	172	172	99	MOLECULE: FERRITIN LIGHT CHAIN;
4	6wx6-C	26.3	0.3	172	172	99	MOLECULE: FERRITIN LIGHT CHAIN;
5	6wx6-A	26.3	0.3	172	172	99	MOLECULE: FERRITIN LIGHT CHAIN;
6	6wx6-O	26.3	0.3	172	172	99	MOLECULE: FERRITIN LIGHT CHAIN;
7	6wx6-N	26.3	0.3	172	172	99	MOLECULE: FERRITIN LIGHT CHAIN;
8	6wx6-T	26.3	0.3	172	172	99	MOLECULE: FERRITIN LIGHT CHAIN;
9	6wx6-G	26.3	0.3	172	172	99	MOLECULE: FERRITIN

							LIGHT CHAIN;
10	6wx6-J	26.3	0.3	172	172	99	MOLECULE: FERRITIN LIGHT CHAIN;

Ερώτηση 3

Υλοποιώ ένα βασικό δέντρο επιθημάτων με την χρήση συναρτήσεων εισαγωγής, διαγραφής, ενημέρωσης και αναζήτησης, επιδεικνύοντας τις θεμελιώδεις πράξεις (εισαγωγή, διαγραφή, ενημέρωση και αναζήτηση) που απαιτούνται για τη δυναμική διατήρηση του γενικευμένου δέντρου επιθήματος. Η κλάση SuffixTree χρησιμοποιεί την κλάση Node για να αναπαραστήσει κάθε κόμβο στο δέντρο, όπου κάθε κόμβος διατηρεί ένα λεξικό θυγατρικών κόμβων και μια λίστα φύλλων που υποδεικνύουν τους δείκτες των επιθημάτων που τελειώνουν σε αυτόν τον κόμβο. Η συνάρτηση εισαγωγής προσθέτει κάθε επίθημα ενός δεδομένου κειμένου στο δέντρο περνώντας από τον ριζικό κόμβο και δημιουργώντας νέους κόμβους όπως απαιτείται. Η συνάρτηση διαγραφής καταργεί κάθε επίθημα διασχίζοντας αναδρομικά το δέντρο και διαγράφοντας τους κόμβους εάν δεν περιέχουν πλέον φύλλα. Η συνάρτηση ενημέρωσης συνδυάζει τη διαγραφή του παλιού κειμένου με την εισαγωγή του νέου κειμένου. Τέλος, η συνάρτηση αναζήτησης ελέγχει εάν ένα δεδομένο μοτίβο υπάρχει στο δέντρο περνώντας μέσα από τους κόμβους που αντιστοιχούν σε κάθε χαρακτήρα του μοτίβου.

Οι προκλήσεις και τα προβλήματα που ανακύπτουν κατά τη δυναμική διατήρηση ενός δέντρου επιθημάτων περιλαμβάνουν τα εξής:

1. Πολυπλοκότητα εισαγωγής:

Όταν χρειάζεται να εισαχθεί μια νέα συμβολοσειρά, το suffix tree ενημερώνεται αναλόγως, περιλαμβάνοντας τη διέλευση του αρχικού δέντρου με σκοπό να βρεθεί η κατάλληλη θέση για την εισαγωγή των νέων επιθημάτων. Αυτό μπορεί να οδηγήσει σε πολυπλοκότητα από γραμμική έως τετραγωνική, ανάλογα με το μέγεθος των συμβολοσειρών και τη δομή του δέντρου.

2. Πολυπλοκότητα διαγραφής:

Η διαγραφή μιας συμβολοσειράς απαιτεί ενημέρωση του δέντρου με τη διέλευση της αρχικής δομής για να αφαιρεθούν τα σχετικά επιθήματα. Αυτή η διαδικασία μπορεί να είναι εξίσου πολύπλοκη με την εισαγωγή, οδηγώντας σε πολυπλοκότητες που κυμαίνονται από γραμμικές έως τετραγωνικές.

3. Κατανάλωση μνήμης:

Τα δέντρα επιθημάτων καταλαμβάνουν σημαντικό χώρο στη μνήμη, ειδικά όταν χειρίζονται μεγάλα σύνολα συμβολοσειρών. Η δυναμική συντήρηση ενός τέτοιου δέντρου μπορεί να αυξήσει περαιτέρω την κατανάλωση μνήμης αν δεν την διαχειρίζεται σωστά.

4. Διαχείριση Πολλαπλών Συμβολοσειρών:

Η διαχείριση πολλαπλών συμβολοσειρών μπορεί να περιπλέξει τη δομή του δέντρου. Για να διαχωριστούν οι συμβολοσειρές, μπορεί να χρειαστεί να ενσωματωθούν μοναδικοί χαρακτήρες τέλους για κάθε συμβολοσειρά, προσθέτοντας πολυπλοκότητα στη διατήρηση και την ενημέρωση της δομής.

Κώδικας

```
class Node:
```

```
    def __init__(self):
```

```
        self.children = {} # Λεξικό για αποθήκευση κόμβων παιδιών.
```

```
        self.leaves = [] # Λίστα για αποθήκευση των ευρετηρίων των επιθημάτων  
        που τελειώνουν σε αυτόν τον κόμβο.
```

```
class SuffixTree:
```

```
    def __init__(self):
```

```
        self.root = Node() # Ριζικός κόμβος του δέντρου επιθημάτων.
```

```
    def insert(self, text):
```

```
        # Εισάγει κάθε επίθημα του κειμένου στο δέντρο επιθημάτων.
```

```
        for i in range(len(text)):
```

```
            self._insert_suffix(text[i:], i)
```

```
    def _insert_suffix(self, suffix, index):
```

```
        current_node = self.root
```

```
        for char in suffix:
```

```

        if char not in current_node.children:
            current_node.children[char] = Node()
        current_node = current_node.children[char]
        current_node.leaves.append(index)

def delete(self, text):
    # Διαγράφει κάθε επίθημα του κειμένου από το δέντρο επιθημάτων.
    for i in range(len(text)):
        self._delete_suffix(text[i:])

def _delete_suffix(self, suffix):
    def _remove_suffix(node, suffix):
        if not suffix: # # Αν το επίθημα είναι άδειο, αφαιρεί όλα τα φύλλα.
            node.leaves = []
            return
        char = suffix[0]
        if char in node.children:
            _remove_suffix(node.children[char], suffix[1:])
            if not node.children[char].leaves: # # Αν ο κόμβος παιδί δεν έχει
                φύλλα, τον αφαιρεί
                del node.children[char]

    _remove_suffix(self.root, suffix)

def update(self, old_text, new_text):
    # First delete the old text, then insert the new text
    self.delete(old_text)
    self.insert(new_text)

```

```

def search(self, pattern):
    # Search for pattern in the suffix tree
    current_node = self.root
    for char in pattern:
        if char not in current_node.children:
            return False
        current_node = current_node.children[char]
    return True

```

Παράδειγμα Χρήσης:

```

suffix_tree = SuffixTree()
suffix_tree.insert("banana")
print(suffix_tree.search("ana")) # 'Εξοδος: True
suffix_tree.delete("ana")
print(suffix_tree.search("ana")) # 'Εξοδος: False
suffix_tree.update("ban", "band")
print(suffix_tree.search("and")) # 'Εξοδος: True

```

Συμπερασματικά, για να βελτιωθεί η λειτουργικότητα και η αποτελεσματικότητα του γενικευμένου δέντρου επιθημάτων για πολλαπλές συμβολοσειρές, είναι σημαντικό να ληφθούν υπόψη οι προκλήσεις και τα προβλήματα που προκύπτουν από τη δυναμική διατήρηση της δομής, όπως η πολυπλοκότητα εισαγωγής και διαγραφής, καθώς και η κατανάλωση μνήμης. Χρησιμοποιώντας βελτιστοποιημένες δομές δεδομένων και αλγόριθμους, μπορούμε να επιτύχουμε καλύτερη απόδοση και αποδοτικότητα στη διαχείριση πολλαπλών συμβολοσειρών.

Ερώτηση 4

Για τον εντοπισμό των επαναλαμβανόμενων συμβολοσειρών σε μία συλλογή από k ακολουθίες, γίνεται η κατασκευή γενικευμένου δένδρου επιθημάτων (generalized suffix tree). Αρχικά, δημιουργώ ένα δένδρο επιθημάτων για κάθε ακολουθία της συλλογής. Έπειτα γίνεται η διάσχιση κάθε δέντρου για να αναγνωριστούν οι επαναλαμβανόμενες υπό συμβολοσειρές που εμφανίζονται περισσότερες από μία φορές στην ίδια ακολουθία. Για κάθε επαναλαμβανόμενη υποσυμβολοσειρά που εντοπίζεται, γίνεται έλεγχος αν υπάρχει και στα δέντρα επιθημάτων των άλλων ακολουθιών. Εάν μια επαναλαμβανόμενη υποσυμβολοσειρά βρεθεί σε όλες τις ακολουθίες, υποδηλώνει μια επανάληψη σε όλες τις ακολουθίες, οπότε γίνεται καταγραφή των αρχικών θέσεων αυτών των επαναλήψεων σε κάθε ακολουθία.

Αυτός ο αλγόριθμος είναι αποδοτικός καθώς επιτρέπει την εύρεση επαναλαμβανόμενων υποσυμβολοσειρών με βάση το σύνολο των ακολουθιών, χρησιμοποιώντας τη δομή των δένδρων επιθημάτων για γρήγορη αναζήτηση. Επιπλέον, μπορεί να επεκταθεί για να λαμβάνει υπόψη περιορισμούς στα κενά ανάμεσα στις εμφανίσεις της συμβολοσειράς, αν και αυτό αυξάνει την πολυπλοκότητα της λύσης. Η βασική αναζήτηση επαναλαμβανόμενων υποσυμβολοσειρών μπορεί να γίνει σε γραμμικό χρόνο χρησιμοποιώντας δένδρα επιθημάτων, αλλά η προσθήκη περιορισμών απαιτεί επιπλέον ελέγχους και υπολογισμούς, γεγονός που μπορεί να αυξήσει την πολυπλοκότητα από πολυωνυμικό έως και εκθετικό χρόνο. Παρόλο που η χρήση του γενικευμένου δένδρου επιθημάτων είναι αποδοτική, ενδέχεται να απαιτεί μεγάλο χώρο μνήμης, ιδιαίτερα για μεγάλες ακολουθίες ή μεγάλα σύνολα δεδομένων. Ωστόσο, η χρήση τεχνικών όπως τα k -mers μπορεί να βοηθήσει στη μείωση αυτών των απαιτήσεων.

Κώδικας:

```
class Node:
```

```
    def __init__(self):
        self.children = {}
        self.indexes = []
```

```
class SuffixTree:
```

```

def __init__(self):
    self.root = Node()

def insert(self, text, sequence_index):
    # Insert all suffixes of the text into the suffix tree
    for i in range(len(text)):
        self._insert_suffix(text[i:], i, sequence_index)

def _insert_suffix(self, suffix, index, sequence_index):
    current_node = self.root
    for char in suffix:
        if char not in current_node.children:
            current_node.children[char] = Node()
        current_node = current_node.children[char]
    current_node.indexes.append((sequence_index, index))

def find_repeated_substrings(self, min_occurrences):
    repetitions = []
    self._find_repetitions(self.root, "", repetitions, min_occurrences)
    return repetitions

def _find_repetitions(self, node, current_string, repetitions, min_occurrences):
    if len(node.indexes) >= min_occurrences and current_string:
        repetitions.append(current_string)
    for char, child in node.children.items():
        self._find_repetitions(child, current_string + char, repetitions,
min_occurrences)

```



```

def find_common_repeated_substrings(sequences):
    if not sequences:
        return []

    # Find all substrings of the first sequence that appear at least twice
    substrings = set()
    first_sequence = sequences[0]

    # Using a dictionary to count substrings
    substring_count = {}
    for i in range(len(first_sequence)):
        for j in range(i + 1, len(first_sequence) + 1):
            substring = first_sequence[i:j]
            if substring in substring_count:
                substring_count[substring] += 1
            else:
                substring_count[substring] = 1

    # Collect substrings that appear at least twice in the first sequence
    for substring, count in substring_count.items():
        if count > 1:
            substrings.add(substring)

    # Filter substrings that appear in all sequences
    common_substrings = [s for s in substrings if all(s in seq for seq in sequences)]

    # Sort by length (longest first) and then alphabetically

```

```

common_substrings.sort(key=lambda x: (-len(x), x))

# Remove substrings that are contained within others
result = []

for s in common_substrings:
    if not any(s != t and s in t for t in result):
        result.append(s)

return result

# Example usage:
sequences = ["ababab", "babab", "abab"]
repetitions = find_common_repeated_substrings(sequences)
print("Common Repeated Substrings:", repetitions)

```

Ερώτηση 5

Για να βρεθούν όλες οι δευτερεύουσες διαδρομές οι οποίες ξεκινούν από τη ρίζα και περιέχουν το πρότυπο P , μπορεί να εκτελεστεί ο αλγόριθμος αναζήτησης κατά βάθος (DFS). Η διέλευση του δέντρου με DFS επιτρέπει την εξερεύνηση όλων των πιθανών μονοπατιών από τη ρίζα, ενώ ελέγχεται και η εμφάνιση συγκεκριμένων μοτίβων σε κάθε κόμβο. Ο αλγόριθμος αρχικά ξεκινά από τη ρίζα και συσσωρεύει τους χαρακτήρες των ετικετών των κόμβων στο τρέχον μονοπάτι. Κάθε φορά που προστίθεται ένας νέος κόμβος στο μονοπάτι, ελέγχεται εάν το πρότυπο P υπάρχει στο συσσωρευμένο μονοπάτι. Εάν βρεθεί το πρότυπο, το μονοπάτι αυτό προστίθεται στη λίστα των αποτελεσμάτων. Αυτός ο αλγόριθμος είναι αποδοτικός καθώς ο χρόνος εκτέλεσής του είναι ανάλογος του συνολικού αριθμού των χαρακτήρων στις ακμές του δέντρου συν το μήκος του προτύπου P .

Επιπλέον, για να καλυφθεί η απαίτηση ότι το υπομονοπάτι πρέπει να είναι τμήμα μονοπατιού που ξεκινά από τη ρίζα, αλλά το ίδιο το υπομονοπάτι δεν χρειάζεται να ξεκινά από τη ρίζα, ο αλγόριθμος περιλαμβάνει έναν επιπλέον βρόχο DFS που ξεκινά από κάθε παιδί του τρέχοντος κόμβου με νέο μονοπάτι. Αυτή η προσέγγιση

διασφαλίζει ότι όλα τα δυνατά υπομονοπάτια που περιέχουν το πρότυπο P θα εντοπιστούν, ακόμα κι αν δεν ξεκινούν απευθείας από τη ρίζα. Τελικά, η συνάρτηση επιστρέφει μια λίστα με όλα τα υπομονοπάτια που πληρούν τα κριτήρια.

Κώδικας:

```
class TreeNode:
    def __init__(self, label):
        self.label = label
        self.children = []

def find_subpaths_with_pattern(root, pattern):
    subpaths = []

    def dfs(node, current_path):
        new_path = current_path + node.label
        # Check for pattern in the current path
        if pattern in new_path:
            subpaths.append(new_path)
        # Continue DFS traversal
        for child in node.children:
            dfs(child, new_path)
        # Additionally, start a new path from each child to allow subpaths that don't
        # start at root
        for child in node.children:
            dfs(child, "")

    dfs(root, "")
    return subpaths
```

```

# Example Usage

if __name__ == "__main__":
    # Create the sample tree based on the image
    root = TreeNode("a")
    x = TreeNode("x")
    a1 = TreeNode("a")
    q1 = TreeNode("q")
    a2 = TreeNode("a")
    q2 = TreeNode("q")
    r1 = TreeNode("r")
    a3 = TreeNode("a")
    z = TreeNode("z")
    r2 = TreeNode("r")

    root.children.append(x)
    root.children.append(a1)
    a1.children.append(q1)
    q1.children.append(a2)
    q1.children.append(r1)
    r1.children.append(a3)
    r1.children.append(z)
    a1.children.append(q2)
    q2.children.append(r2)

    pattern = "aqra"
    subpaths = find_subpaths_with_pattern(root, pattern)

```

```
print("Subpaths containing the pattern:", subpaths)
```

Ερώτηση 6

Ι. Βέλτιστη Ολική Στοίχισης

Και οι δύο ακολουθίες είναι διατεταγμένες σε κάθε πλευρά του πίνακα, ενώ γεμίζουν την πρώτη γραμμή και στήλη με τα πολλαπλάσια του -2. Σε αυτή την περίπτωση τελειώνει στο -20. Μετά από αυτό σε κάθε θέση, η αντιστοίχιση, η αναντιστοιχία ή το κενό υπολογίζονται χρησιμοποιώντας τα δεδομένα που δίνονται. Επιλέγεται το μέγιστο από αυτές τις τιμές και τοποθετείται ένα βέλος για να υποδείξει το προηγούμενο κελί που παρείχε αυτήν τη μέγιστη τιμή. Μόλις συμπληρωθούν όλες οι θέσεις, η διαδρομή διασχίζεται προς τα πίσω, επιλέγοντας τη μέγιστη τιμή σε κάθε βήμα και επισημαίνοντας το βέλος που ήταν υπεύθυνο για αυτήν. Με αυτόν τον τρόπο υπολογίζεται η συνολική στοίχιση.

Λύση:

	-	G	U	G	T	T	G	T	G	G
-	-2	-4	-6	-8	-10	-12	-14	-16	-18	-20
T	-4	-3	-4	-5	-6	-7	-8	-9	-10	-11
C	-6	-4	-4	-5	-6	-7	-8	-9	-10	-11
G	-8	-5	-5	-3	-4	-5	-6	-7	-8	-9
T	-10	-6	-6	-4	-2	-3	-4	-5	-6	-7
G	-12	-7	-7	-5	-3	-3	-2	-3	-4	-5
A	-14	-8	-8	-6	-4	-4	-3	-3	-4	-5
A	-16	-9	-9	-7	-5	-5	-4	-4	-4	-5
T	-18	-10	-10	-8	-6	-4	-5	-3	-4	-5
T	-20	-11	-11	-9	-7	-5	-5	-4	-4	-5

G U G T T _ _ _ G T G G

T C G _ T G A _ T _ T

II. Βέλτιστη Τοπική Στοίχιση

Για να πραγματοποιηθεί τοπική στοίχιση, οι ακολουθίες τοποθετούνται και στις δύο πλευρές ενός πίνακα, με την πρώτη γραμμή και στήλη γεμάτη με μηδενικά. Οι υπολογισμοί εκτελούνται παρόμοια με την καθολική στοίχιση, αλλά η μόνη διαφορά είναι ότι οποιαδήποτε αρνητική τιμή αντικαθίσταται από 0. Τέλος, επιλέγονται θέσεις με τις μέγιστες βαθμολογίες για να επιτευχθεί η βέλτιστη τοπική στοίχιση των ακολουθιών.

Λύση:

	-	G	U	G	T	T	G	T	G	G
-	0	0	0	0	0	0	0	0	0	0
T	0	0	0	0	1	1	0	1	0	0
C	0	0	0	0	0	0	0	0	0	0
G	0	1	0	1	0	0	1	0	1	1
T	0	0	0	0	2	1	0	2	0	0
G	0	1	0	1	0	0	2	0	3	1
A	0	0	0	0	0	0	0	0	0	0
A	0	0	0	0	0	0	0	0	0	0
T	0	0	0	0	1	1	0	1	0	0
T	0	0	0	0	1	2	0	1	0	0

G T G

G T G

Ερώτηση 7

Ο ακόλουθος κώδικας αντιμετωπίζει αποτελεσματικά την αναγνώριση περιοχών δέσμευσης για καθορισμένους παράγοντες μεταγραφής (TF), την εμφάνιση και την αποθήκευση των θέσεων τους, τον υπολογισμό στατιστικών στοιχείων ακολουθίας και τη δημιουργία συμπληρωματικών και μεταγραφόμενων ακολουθιών. Αρχικά φορτώνεται η ακολουθία DNA από το αρχείο FASTA. Αυτή η ακολουθία στη συνέχεια μετατρέπεται σε μορφή συμβολοσειράς για ευκολότερο χειρισμό. Τα μοτίβα δέσμευσης TF ορίζονται σε ένα λεξικό με τις αντίστοιχες συναινετικές αλληλουχίες τους, οι οποίες στη συνέχεια χρησιμοποιούνται για την εύρεση περιοχών δέσμευσης εντός της φορτωμένης αλληλουχίας.

Για τον προσδιορισμό περιοχών, χρησιμοποιείται η συνάρτηση `find_binding_regions`, η οποία χρησιμοποιεί κανονικές εκφράσεις για την αναζήτηση μοτίβων που αντιστοιχούν στις θέσεις δέσμευσης των RUNX1, TGIF1 και IKZF1 εντός της αλληλουχίας DNA. Όταν βρεθεί ένα μοτίβο, οι θέσεις έναρξης και λήξης καταγράφονται και εκτυπώνονται. Αυτές οι θέσεις γράφονται επίσης στο αρχείο εξόδου `binding_regions.txt`, διασφαλίζοντας ότι τα αποτελέσματα εμφανίζονται και αποθηκεύονται. Έτσι πιστοποιείται ότι πληρούνται οι απαιτήσεις αναγνώρισης και αποθήκευσης των δεσμευτικών περιοχών για κάθε καθορισμένο παράγοντα μεταγραφής.

Επιπλέον υπολογίζω και καταγράφω τα στατιστικά αλληλουχίας μέσω της συνάρτησης `calculate_statistics`, που υπολογίζει τον συνολικό αριθμό των βάσεων και το ποσοστό των βάσεων κυτοσίνης (C) και γουανίνης (G) στην αλληλουχία, τα οποία είναι κρίσιμα για την κατανόηση της σύνθεσης του DNA. Τα αποτελέσματα αποθηκεύονται στο αρχείο `sequence_statistics.txt`. Επίσης, με την χρήση των συναρτήσεων `write_complementary_sequence` και `write_post_transcribed_sequence`, δημιουργώ τη συμπληρωματική αλληλουχία DNA και την αλληλουχία RNA μετά τη μεταγραφή, αντίστοιχα. Αυτές οι παραγόμενες ακολουθίες αποθηκεύονται σε ξεχωριστά αρχεία, `complementary_sequence.fasta` και `post_transcribed_sequence.fasta`. ακολουθιών.

Κώδικας:

```
from Bio import SeqIO
from Bio.Seq import Seq
from Bio.SeqRecord import SeqRecord
import re

def find_binding_regions(sequence, tf_name, tf_pattern):
    binding_regions = []

    for match in re.finditer(tf_pattern, sequence):
        print(tf_pattern)
```

```

    print(sequence)
    start = match.start()
    end = match.end()
    binding_regions.append((start, end))
    print(f"Binding region found for {tf_name}: {start+1}-{end}")
return binding_regions

def calculate_statistics(sequence):
    num_bases = len(sequence)
    num_cg = sequence.count('C') + sequence.count('G')
    cg_percentage = (num_cg / num_bases) * 100
    return num_bases, cg_percentage

def write_complementary_sequence(sequence, output_file):
    # Convert the sequence string to a Bio.Seq object
    bio_seq = Seq(sequence)

    # Get the complementary sequence
    complementary_seq = bio_seq.complement()

    # Write the complementary sequence to the output file
    with open(output_file, "w") as f:
        f.write(str(complementary_seq) + "\n")

def write_post_transcribed_sequence(sequence, output_file):
    # Convert the sequence string to a Bio.Seq object
    bio_seq = Seq(sequence)

```



```

# Transcribe the sequence to RNA
rna_seq = bio_seq.transcribe()

# Write the transcribed RNA sequence to the output file
with open(output_file, "w") as f:
    f.write(str(rna_seq) + "\n")

def main():
    # Load sequence from FASTA file
    input_file="seq.fasta"
    sequence_record = SeqIO.read(input_file, "fasta")
    sequence = str(sequence_record.seq)
    print(sequence)
    print(type(sequence))

    # TF binding regions
    tf_bindings = {
        "RUNX1": (r"[CGT][ACT]TGTGGT[CT][AT]", "RUNX1"),
        "TGIF1": (r"[AT]GACAG[CGT]", "TGIF1"),
        "IKZF1": (r"[CGT]TGGGA[AG][AGT]", "IKZF1"),
        #"TF2": ("TF2_pattern", "TF2_name"),
    }
    binding_regions_file = "binding_regions.txt"
    with open(binding_regions_file, "w") as f:
        for tf_name, (tf_pattern, _) in tf_bindings.items():
            print(tf_pattern)

```

```

binding_regions = find_binding_regions(sequence, tf_name, tf_pattern)
f.write(f"Binding regions for {tf_name}:\n")
for start, end in binding_regions:
    f.write(f"{start+1}-{end}\n")

# Sequence statistics
num_bases, cg_percentage = calculate_statistics(sequence)
stats_file = "sequence_statistics.txt"
with open(stats_file, "w") as f:
    f.write(f"Number of bases: {num_bases}\n")
    f.write(f"Percentage of CG: {cg_percentage:.2f}%\n")

# Complementary sequence
complementary_file = "complementary_sequence.fasta"
write_complementary_sequence(sequence, complementary_file)

# Post-transcribed sequence
post_transcribed_file = "post_transcribed_sequence.fasta"
write_post_transcribed_sequence(sequence, post_transcribed_file)

if __name__ == "__main__":
    main()

```